研脉 PaperWeave：从论文 PDF 到证据溯源思维导图的本地一键转换系统

技术报告与界面测试评估

xxraincandyxx
南京邮电大学
xxraincandyxx@gmail.com

摘要

学术论文篇幅长、结构复杂、术语密集，读者难以快速把握研究主题、论证路径与局限。本文报告研脉（PaperWeave）系统的设计与实现：该系统将文本型学术论文 PDF 一键转换为带证据溯源的 Mermaid 思维导图与可离线打开的交互式 HTML 看板，覆盖**页级解析、来源分块、大模型结构化分析、证据核验、主题合并、导图校验与单文件导出**七个阶段。系统以归一化摘录匹配支撑证据回溯，以完整性校验防止节点静默丢失，并在真实 Chromium 内核中验证 Mermaid 语法后内嵌全部渲染资源，保证看板断网可用。我们在 macOS 与 Windows 两种环境下执行 14 项自动化测试并完成 12 个关键功能的浏览器级界面测试，全部通过；系统对陌生双栏论文与离线场景表现稳定。对照“文档解析智能体设计大赛”评审维度，基础部分全部达成，提高部分大部分达成；科学分析质量有待真实模型接入后的现场验收。

1 引言

阅读学术论文的核心困难不在于单句理解，而在于把握全文结构：研究问题是什么、论证如何展开、贡献与局限分别在哪里。大语言模型为自动结构化分析提供了可能，但直接调用模型存在三类风险：模型可能编造原文不存在的内容；分析往往只覆盖前几页而遗漏末页证据；生成的导图依赖在线服务，不可归档、不可离线分享。

“文档解析智能体设计大赛”将上述问题形式化为一条自动化流水线：PDF 输入 → 文本提取 → 论文结构分析 → Mermaid 导图生成 → 交互式 HTML 看板输出，并要求全程一键完成、不依赖外部 CDN、分析结果可回溯。本文报告我们按该要求实现的研脉系统，重点包括：（1）以来源块为单位的全文覆盖式分析设计 §2;(2)证据核验与完整性保障机制 §2.2;(3)自动化测试与端到端界面测试的结果 §3。

2 系统设计

系统由 PyMuPDF4LLM 按物理页提取文本 (PyMuPDF Team, 2025)，复用 ScholarFlow 的数据模型与章节识别 (ScholarFlow Team, 2026)，改造 mindmap-generator 的递归导图生成方式 (Stone, 2025)，经 FastAPI 提供本地上传服务 (Ramírez et al., 2025)，并用 Playwright 驱动真实浏览器完成渲染校验 (Microsoft, 2025)。图 1 展示整体流程。

2.1 文档解析与来源分块

解析阶段每页独立提取，异常页回退到 PyMuPDF 原生读取并给出阅读顺序警告；可提取文字不足的页面被标记为疑似扫描页，不静默跳过。论文标题在元数据缺失时按首页最大字号、水平走向与纵向位置启发式识别，避免将版权声明误认作标题。全文被切分为不超过 1200 字符的**来源块**，每个来源块携带物理页码、所属章节与稳定 ID（如 p0003b0007）。来源块按字符预算组成分析块，长度上限可配置，默认 10000 字符；实验表明 15 页双栏论文产生 254 个来源块、7 个分析块，末页内容同样进入分析覆盖记录。

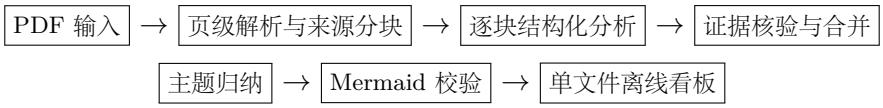


图 1: 研脉处理流水线。除大模型分析阶段外全部本地执行；分析阶段按块依次调用 Chat Completions 兼容接口，配置经 .env 或环境变量注入。



图 2: 本地上传工作台。左：入口页自动检测模型配置并显示所用模型；右：上传后进度条实时更新阶段与分块进度，全程无需输入提示词或人工指定结构。

2.2 结构化分析与证据核验

每个分析块单独请求模型，提示词要求返回固定结构的 JSON：发现列表，每项含节点名称、内容主题、九选一的类别标签、详细分析、读者友好解释、推断标记与证据引用。返回结果经过三层校验：JSON 结构与枚举合法性；证据 source_id 必须属于当前分析块（而非全篇）；摘录经 Unicode NFKC 与空白归一化后必须能在来源块原文中逐字找到。校验失败时将错误回传模型修复，至多两次；仍失败则终止并保留已提取内容。

该设计有两个值得强调的取向。其一，**证据只证明引文存在，不证明结论成立**：界面上“摘录匹配”与“语义待核对”始终并列显示（图 4），推断性节点单独标记，未匹配摘录保留醒目标记而不伪造通过。其二，**全文覆盖优先**：所有分析块依次处理，不因已发现足够主题而提前结束，从机制上避免“只读摘要”类工具丢失末页局限的问题。

2.3 合并、归纳与完整性检查

去重采取保守策略：仅当类别、推断标记与详细分析三者归一化一致（或名称相似度超过 0.96）时才合并节点，语义相反的结论不会被错误聚合。主题归纳按批（每批不超过 24 个节点）请求模型将发现归入 2–6 个内容主题，不套用固定模板；每个输入节点 ID 必须恰好分配一次，最终树叶节点集合必须等于全部分析节点，否则终止导出。该完整性断言使合并环节的节点丢失从“静默缺陷”变为“显式错误”。

2.4 导图校验与离线看板

同一主题树生成 Mermaid mindmap 与 flowchart 两种格式，均先经真实 mermaid.parse() 校验 (Sveidqvist et al., 2025)，再在 Chromium 中实际渲染为 SVG；标签含非常规字符导致解析失败时，按规则清洗标签结构字符后重试。看板为单文件 HTML：样式、交互脚本、Mermaid 渲染器、结构化数据与预渲染 SVG 全部内嵌，可选内嵌原始 PDF。生成的文件以 file:// 直接打开即可使用，自动化测试验证离线模式下无任何 HTTP(S) 请求。

看板交互包括：节点索引与全文关键词搜索、局限与边界筛选、思维导图与结构关系图切换、拖拽平移与滚轮缩放、主题收起展开、节点详情与证据面板（页码按钮跳转原文并高亮摘录）、HTML/SVG/Mermaid/JSON 四种导出、深浅主题切换与移动端适配。

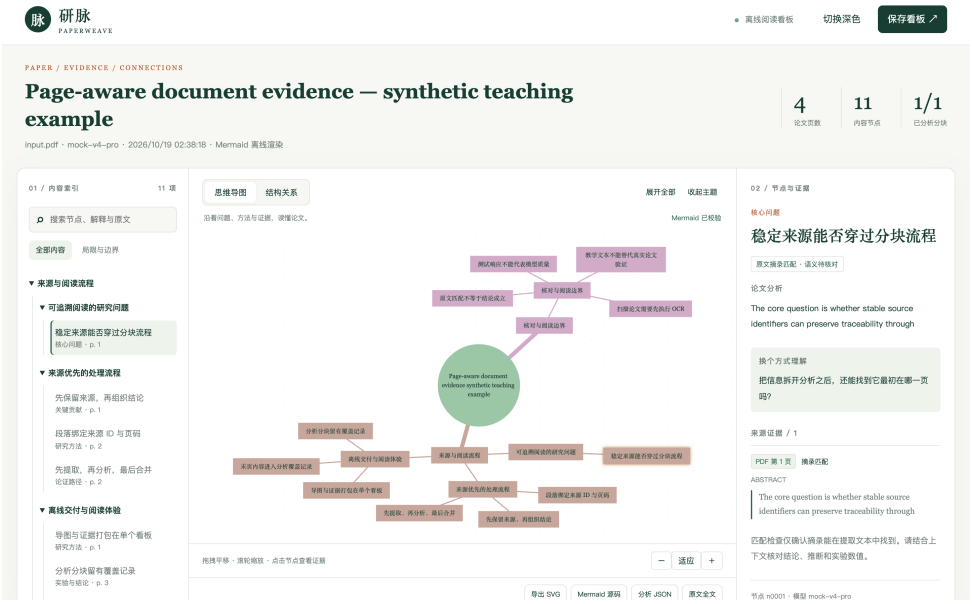


图 3: 离线看板全貌：左栏为节点索引、关键词搜索与“局限/边界”筛选；中栏为 Mermaid 思维导图，支持拖拽、缩放、收起展开与结构关系图切换；右栏为选中节点的类别、分析、通俗解释与证据卡片。页眉统计页数、节点数与分块覆盖。



图 4: 证据溯源。左：证据卡片显示物理页码按钮、章节、逐字摘录与匹配状态，“摘录匹配”与“语义待核对”并列提示；右：点击页码后原文对话框按页呈现提取文本，命中摘录高亮，并可切换查看内嵌原始 PDF。

2.5 本地服务与安全边界

上传服务仅监听回环地址，校验 Host 与 Origin 头以阻断跨站请求与 DNS 重绑定；并发任务上限 3 个，单文件上限 80 MB，结果文件按白名单路由。API Key 仅经环境变量或 .env 注入，不写入源码、日志与导出文件；认证失败的响应正文不落盘。

3 测试与评估

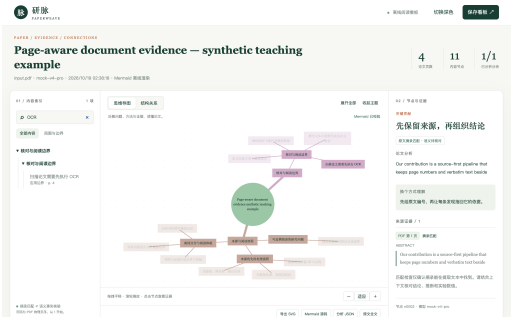
3.1 自动化测试

测试套件共 14 项，全部通过（macOS 15 / Python 3.14 与 Windows / Python 3.12 双环境实测）。表 1 按验证目标归纳。其中浏览器级上传流程测试为本轮新增：以确定性模拟接口[1]替代真实模型，经 uvicorn 临时端口与 Playwright 自动完成“上传 PDF → 任务轮询 → 打开看板 → 断言 SVG 渲染”全流程。

3.2 陌生论文与离线核查

以公开论文《Attention Is All You Need》(Vaswani et al., 2017) 作为开发中不可见的真实双栏 PDF 进行抽取核查：254 个来源片段全部恰好分配至 7 个分析块，第 14 页文字不足的警告被正确保留而非掩盖。离线方面，对生成的看板以浏览器离线上下文加载，外部资

[1] 模拟响应复用教学规则，仅覆盖教学样例关键词，不代表真实模型质量。



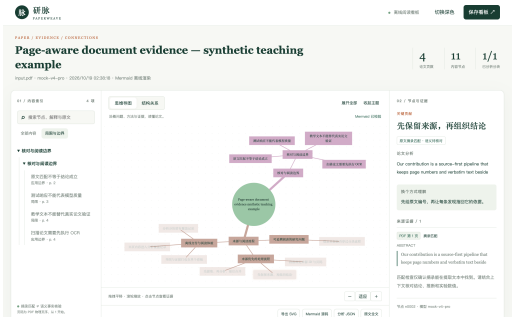


图 5: 检索与筛选。左：搜索“OCR”时索引收敛为 1 项，导图中不相关节点降低不透明度；右：“局限与边界”筛选仅保留局限性与应用边界类节点，便于快速核查论文自述局限。



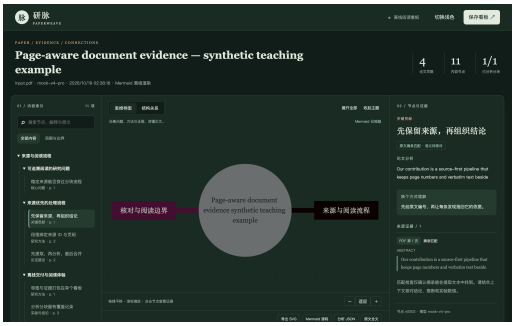


图 6: 视图切换。左：结构关系图以有向层级呈现同一主题树，连线仅表示归属；右：深色主题下导图与面板同步重渲染，Mermaid 校验状态实时显示。

验证目标	测试要点
全文覆盖	分块无截断；末页内容进入导图
证据核验	伪造摘录标记为未匹配；证据必须归属当前块
合并安全	树完整保留；语义相反的结论不合并
异常处理	加密/扫描 PDF 给出可操作错误
协议健壮	非法 JSON 修复；密钥脱敏；401 不泄露正文
界面流程	上传 → 轮询 → 看板打开（新增）
离线交互	断网渲染、节点点击、四种导出、移动端
访问控制	跨站请求 403；结果文件白名单

表 1: 自动化测试覆盖（14 项全部通过）。

源请求计数为 0；看板体积约 2.8 MB（内嵌原始 PDF 时），可在移动端正常滚动与缩放。

3.3 端到端界面测试

我们在浏览器中对 12 项关键功能逐一操作并截图（图 2–7）：配置检测、文件选择、进度反馈、完成跳转、导图渲染、节点选择、证据定位、原文高亮、关键词搜索、局限性筛选、结构图切换、深色主题、主题折叠与移动端布局，全部符合预期。测试经本地模拟模型接口驱动真实上传流程完成，看板由该次运行实际生成而非预置文件。

4 与比赛要求的对照

表 2 对照大赛评审维度给出状态。基础部分（提取、分析、导图、看板、一键化）全部达成；提高部分中页码溯源、搜索、导图切换、导出、主题切换、语法自动修复与读者友好解释均已实现，未声称完成的包括图像公式理解、自动 OCR 与独立语义事实核验。

5 局限与展望

系统目前存在四点局限。（1）**模型质量未经验收**：全部定量结果基于确定性模拟响应或抽取层核查，接入主办方 DeepSeek V4 Pro(DeepSeek-AI, 2024) 后的科学分析准确率仍需人工核验；（2）**文本型 PDF 边界**：扫描

评审维度	分值	状态与依据
一键跑通	30	已达成：命令行与上传界面均一次触发全流程
解析准确	25	机制就绪并经真实双栏 PDF 抽取核查；语义质量待真实模型验收
看板可用	20	已达成：离线 0 外部请求，交互齐全
内容深度	20	已实现：页码/章节/摘录溯源、批判性标注、通俗解释
稳定鲁棒	15	已实现：JSON 修复、网络重试、导图规则修复、完整性断言
工程规范	10	已达成：文档完备、密钥不落盘、依赖可复现

表 2: 与大赛评审维度的对照（合计 120 分）。



图 7: 移动端（390 pt 视口）：三栏折叠为单列纵向排布，索引、导图与详情仍可独立操作，无横向溢出。

件与图片型公式超出基础承诺，系统以显式警告而非静默降级处理；（3）**摘录匹配非蕴含判定**：证据核验只能确认引文存在，结论正确性仍需读者结合上下文判断；（4）**跨平台验证范围**：macOS 环境为本轮补充实测，正式提交材料仍以已声明的 Windows/Python 3.12 组合为准。后续计划接入独立语义核验通道，并探索分栏阅读顺序的显式建模。

6 结论

研脉系统以来源块与证据核验为中心组织整条流水线，将“模型会出错”作为设计前提而非异常路径，实现了从论文 PDF 到证据可溯、可离线使用的思维导图看板的一键转换。14 项自动化测试与 12 项界面功能测试全部通过，陌生论文抽取与离线场景核查未发现阻断性缺陷。系统已具备比赛基础部分的完整能力，剩余工作集中于真实模型接入后的质量验收。

References

DeepSeek-AI. 2024. DeepSeek-V3 technical report. arXiv preprint arXiv:2412.19437.

Microsoft. 2025. Playwright. https://playwright.dev.

PyMuPDF Team. 2025. PyMuPDF4LLM: LLM-friendly PDF text extraction. https://github.com/pymupdf/pymupdf4llm. AGPL-3.0，版本 1.28.2.

Sebastián Ramírez et al. 2025. FastAPI. https://fastapi.tiangolo.com.

ScholarFlow Team. 2026. ScholarFlow. https://github.com/bcefghj/scholarflow. Commit cc66f78，MIT.

Jeffery D. Stone. 2025. mindmap-generator. https://github.com/Dicklesworthstone/mindmap-generator. Commit 4b835da.

Knut Sveidqvist et al. 2025. Mermaid: Diagramming and charting tool. https://mermaid.js.org. 版本 11.12.0.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In Advances in Neural Information Processing Systems.