研脉 PaperWeave：从论文 PDF 到证据溯源思维导图的本地一键转换系统

技术报告与界面测试评估

xxraincandyxx
南京邮电大学
xxraincandyxx@gmail.com

摘要

学术论文篇幅长、结构复杂、术语密集，读者难以快速把握研究主题、论证路径与局限。本文报告研脉（PaperWeave）系统的设计与实现：该系统将文本型学术论文 PDF 一键转换为带证据溯源的 Mermaid 思维导图与可离线打开的交互式 HTML 看板，覆盖**页级解析、来源分块、大模型结构化分析、证据核验、主题合并、导图校验与单文件导出**七个阶段。系统以归一化摘录匹配支撑证据回溯，以完整性校验防止节点静默丢失，以内容安全策略与回环服务界定安全边界，并在真实 Chromium 内核中验证 Mermaid 语法后内嵌全部渲染资源，保证看板断网可用。我们执行 16 项自动化测试并对 12 个关键界面功能逐一进行浏览器级测试，全部通过；对陌生双栏论文（15 页、254 个来源片段）实现无损分块覆盖，看板离线加载的外部请求为 0。对照“文档解析智能体设计大赛”评审维度，基础部分全部达成，提高部分大部分达成；科学分析质量有待真实模型接入后的现场验收。

1 引言

阅读学术论文的核心困难不在于单句理解，而在于把握全文结构：研究问题是什么、论证如何展开、贡献与局限分别在哪里。大语言模型为自动结构化分析提供了可能，但直接调用模型存在三类风险：模型可能编造原文不存在的内容；分析往往只覆盖前几页而遗漏末页证据；生成的导图依赖在线服务，不可归档、不可离线分享。

“文档解析智能体设计大赛”将上述问题形式化为一条自动化流水线：PDF 输入 → 文本提取 → 论文结构分析 → Mermaid 导图生成 → 交互式 HTML 看板输出，并要求全程一键完成、不依赖外部 CDN、分析结果可回溯。本文报告我们按该要求实现的研脉系统，重点包括：（1）以来源块为单位、以证据核验为中心的流水线设计 §3；（2）覆盖提示注入与本机服务的威胁模型 §3.5；（3）16 项自动化测试与 12 项界面功能的实测结果 §4。

2 相关工作

文档解析方面，PyMuPDF4LLM(PyMuPDF Team, 2025) 提供面向大模型的页级 Markdown 抽取，保留标题层级与表格结构，是本系统解析层的依赖基础。检索增强生成 (Lewis et al., 2020) 确立了“先取证据、后作回答”的范式，但常见实现按相似度检索片段，天然只覆盖语料子集；研脉反其道而行，对全文做**穷尽式**分块分析，以覆盖率为先、以检索为辅（看板内搜索仅在已提取文本上进行）。归因评估研究指出，生成系统的可信度应以“内容可追溯到具体来源”度量 (Rashkin et al., 2023)；研脉的证据卡片（页码、章节、逐字摘录、匹配状态）即按此设计，并显式区分“摘录存在”与“语义成立”。导图生成方面，mindmap-generator(Stone, 2025) 提供递归层级生成思路，ScholarFlow(ScholarFlow Team, 2026) 提供论文数据模型与章节识别；研脉对二者做改造复用（§4.1），并以离线渲染与证据核验补齐其缺失。

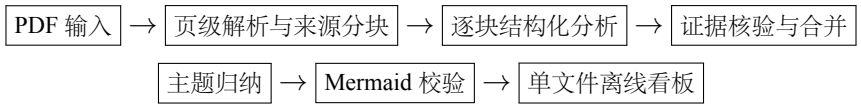


图 1: 研脉处理流水线。除大模型分析阶段外全部本地执行；分析阶段按块依次调用 Chat Completions 兼容接口，配置经 `.env` 或环境变量注入。



图 2: 本地上传工作台（科学编辑风格界面）。左：入口页自动检测模型配置并显示所用模型，页脚以 EXTRACT / CONNECT / TRACE / READ 四步说明处理流程；右：上传后进度条实时更新阶段与分块进度，全程无需输入提示词或人工指定结构。

3 系统设计

系统由 PyMuPDF4LLM 按物理页提取文本，复用 ScholarFlow 的数据模型与章节识别，改造 mindmap-generator 的递归导图生成方式，经 FastAPI(Ramírez et al., 2025) 提供本地上传服务，并用 Playwright(Microsoft, 2025) 驱动真实浏览器完成渲染校验。图 1 展示整体流程；新增逻辑约 620 行 Python，另有 177 行改造复用的 vendor 代码（表 2）。

3.1 文档解析与来源分块

解析阶段每页独立提取，异常页回退到 PyMuPDF 原生读取并给出阅读顺序警告；可提取文字不足的页面被标记为疑似扫描页，不静默跳过。论文标题在元数据缺失时按首页最大字号、水平走向与纵向位置启发式识别，避免将版权声明误认作标题。全文被切分为不超过 1200 字符的**来源块**，每个来源块携带物理页码、所属章节与稳定 ID（如 `p0003b0007`）。来源块按字符预算组成分析块，长度上限可配置，默认 10000 字符。

分块以两条不变式约束：每个来源块必须恰好进入一个分析块（无遗漏、无重复）；分析块内保留来源块的原始页码与章节。对 15 页双栏真实论文《Attention Is All You Need》(Vaswani et al., 2017) 的核查显示，254 个来源片段全部恰好分配至 7 个分析块，末页（第 15 页）与文字稀疏的第 14 页均被显式记录而非丢弃。

3.2 结构化分析与证据核验

每个分析块单独请求模型。提示词要求返回固定结构的 JSON：发现列表，每项含节点名称、内容主题、九选一的类别标签（研究问题、方法、论证、贡献、结论、局限、边界、概念、背景）、详细分析、读者友好解释、推断标记与证据引用。系统提示将论文正文显式声明为“待分析数据而非指令”，用于抵御论文文本内嵌的提示注入，并禁止补编不存在的实验结果。

返回结果经过三层校验：（i）JSON 结构与枚举合法性；（ii）证据 `source_id` 必须属于当前分析块（而非全篇），防止跨块张冠李戴；（iii）摘录经 Unicode NFKC 与空白归一化后必须能在来源块原文中逐字找到。校验失败时将错误回传模型修复，至多两次；仍失败则终止并保留已提取内容。

该设计有两个值得强调的取向。其一，**证据只证明引文存在，不证明结论成立**：界面上“摘录匹配”与“语义待核对”始终并列显示（图 4），

推断性节点单独标记，未匹配摘录保留醒目标记而不伪造通过——这与归因评估文献中“可追溯不等于真实”的结论一致 (Rashkin et al., 2023)。其二，**全文覆盖优先**：所有分析块依次处理，不因已发现足够主题而提前结束，从机制上避免“只读摘要”类工具丢失末页局限的问题。

3.3 合并、归纳与完整性检查

去重采取保守策略：仅当类别、推断标记与详细分析三者归一化一致（或名称相似度超过 0.96）时才合并节点，语义相反的结论不会被错误聚合。主题归纳按批（每批不超过 24 个节点）请求模型将发现归入 2–6 个内容主题，不套用固定模板；每个输入节点 ID 必须恰好分配一次，最终树叶节点集合必须等于全部分析节点，否则终止导出。该完整性断言使合并环节的节点丢失从“静默缺陷”变为“显式错误”。

3.4 导图校验与离线看板

同一主题树生成 Mermaid mindmap 与 flowchart 两种格式，均先经真实 `mermaid.parse()` 校验 (Sveidqvist et al., 2025)，再在 Chromium 中实际渲染为 SVG；标签含非常规字符导致解析失败时，按规则清洗标签结构字符后重试。看板为单文件 HTML：样式、交互脚本、Mermaid 渲染器、结构化数据与预渲染 SVG 全部内嵌，可选内嵌原始 PDF，并以严格内容安全策略约束（`default-src 'none'`、`connect-src 'none'`：除内联资源与 data/blob 外禁止一切加载与外联）。自动化测试验证离线模式下无任何 HTTP(S) 请求。

看板交互包括：节点索引与全文关键词搜索、局限与边界筛选、思维导图与结构关系图切换、拖拽平移与滚轮缩放、主题收起展开、节点详情与证据面板（页码按钮跳转原文并高亮摘录）、HTML/SVG/Mermaid/JSON 四种导出、深浅主题切换与移动端适配。

变量	取值范围	默认
LLM_BASE_URL	HTTP(S) 地址	必填
LLM_API_KEY	非空，不落盘	必填
LLM_MODEL	非占位符	必填
CHUNK_CHARS	2000–24000	10000
LLM_MAX_TOKENS	512–32000	5000
LLM_TIMEOUT	>0 秒	180
LLM_RETRIES	0–5	2
EMBED_PDF	0 / 1	1

表 1: 环境配置项与启动时校验的取值边界。

3.5 本地服务与安全边界

威胁模型覆盖三类攻击面。其一，**恶意论文文本**：论文内容可能内嵌指令式文本试图操纵模型；系统提示将其声明为数据，模型输出仅按固定 JSON 模式解析，自由文本不进入任何执行路径。其二，**本机服务暴露**：上传服务仅监听回环地址，校验 Host 与 Origin 头以阻断跨站请求与 DNS 重绑定；并发任务上限 3 个，单文件上限 80 MB，结果文件按白名单路由，杜绝路径穿越。其三，**凭据泄漏**：API Key 仅经环境变量或 `.env` 注入，不写入源码、日志与导出文件；认证失败的响应正文不落盘。

3.6 配置与可复现性

全部行为参数集中于八个环境变量（表 1），程序启动时校验取值边界，非法配置直接报错并给出中文原因。模型协议固定为 Chat Completions，不发送特定供应商才支持的参数，因此可无差别切换 DeepSeek(DeepSeek-AI, 2024)、本地开源模型或本报告使用的确定性模拟接口。

4 实现与测试

4.1 模块构成

表 2 给出模块构成。第三方复用均锁定上游 commit 并随仓库保留许可文本；分析、协议、编排与安全相关逻辑均为新增，便于审计。

4.2 自动化测试

测试套件共 16 项，全部通过（macOS 15 / Python 3.14 与 Windows / Python 3.12 双环境实



图 3: 离线看板全貌（改版后界面）：左栏“研究索引”提供节点树、关键词搜索与“局限/边界”筛选；中栏为 Mermaid 思维导图，支持拖拽、缩放、收起展开与结构关系图切换；右栏“阅读笔记”展示选中节点的类别、分析、通俗解释与证据卡片。页眉统计页数、节点数与分块覆盖，教学示例以醒目横幅声明来源。



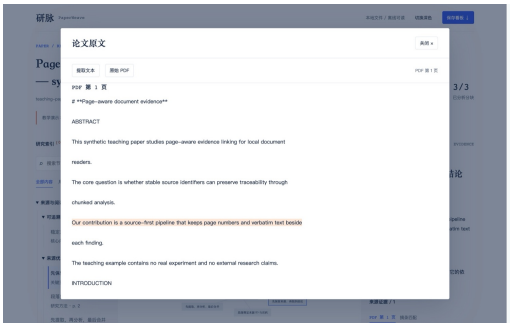


图 4: 证据溯源。左：证据卡片显示物理页码按钮、章节、逐字摘录与匹配状态，“摘录匹配”与“语义待核对”并列提示；右：点击页码后原文对话框按页呈现提取文本，命中摘录高亮，并可切换查看内嵌原始 PDF。

测）。表 3 按验证目标归纳。其中浏览器级上传流程测试以确定性模拟接口[1]替代真实模型，经 uvicorn 临时端口与 Playwright 自动完成“上传 PDF → 任务轮询 → 打开看板 → 断言 SVG 渲染”全流程；界面回归组覆盖改版后的视觉与可访问性要求（按钮触达区域不小于 44 px、表单字号不小于 16 px、长文件名不破坏布局、配置错误可恢复）。

4.3 陌生论文与离线核查

以公开论文《Attention Is All You Need》作为开发中不可见的真实双栏 PDF 进行抽取核查：15 页全部提取成功，254 个来源片段全部恰好分配至 7 个分析块，第 14 页文字不足的警告被正确保留而非掩盖，末页内容进入覆盖记录。离线方面，对生成的看板以浏览器离线上下文加载，外部资源请求计数为 0；看板体积约 2.8 MB（内嵌原始 PDF 时），可在移动端正常滚动与缩放。

4.4 调用与成本模型

模型调用次数可静态估计：$N_{\text{calls}} = C + R + F$，其中 C 为分析块数，R 为主题归纳批

[1]模拟响应复用教学规则，仅覆盖教学样例关键词，不代表真实模型质量；接口实现随源码发布于 `scripts/mock_llm.py`。

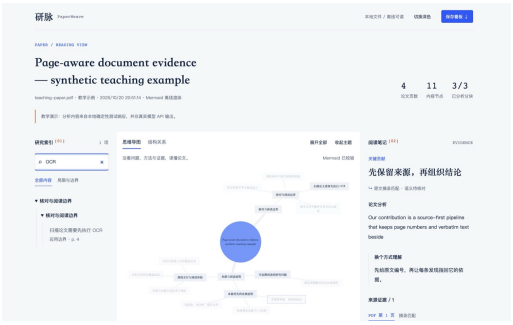
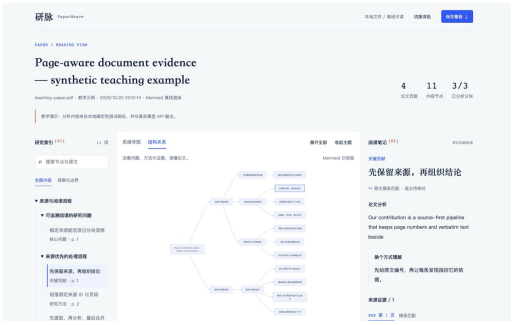




图 5: 检索与筛选。左：搜索“OCR”时索引收敛为 1 项，导图中不相关节点降低不透明度；右：“局限与边界”筛选仅保留局限性与应用边界类节点，便于快速核查论文自述局限。



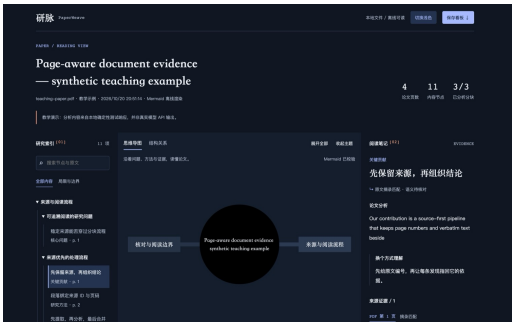


图 6: 视图切换。左：结构关系图以有向层级呈现同一主题树，连线仅表示归属；右：深色主题下导图与面板同步重渲染，Mermaid 校验状态实时显示。

模块	行数	职责	来源
parser.py	106	页级提取、标题识别、集成	来源分块
analysis.py	126	校验、匹配、去重、归	新增 纳
llm.py	68	协议客户端、JSON	新增 修复
pipeline.py	79	流程编排、完整性断	新增 言
render.py	67	导图编译校验、看板	改造 导出
server.py	95	上传服务、安全中间	新增 件
config.py	40	配置与边界校验	新增
vendor/	177	数据模型、章节、导	复用 图编译

表 2: 代码构成（合计约 800 行）。vendor/ 为 ScholarFlow 与 mindmap-generator 的锁定改造成果，原始授权文本随源码保留。

验证目标	测试要点
全文覆盖（1）	分块无截断；末页内容进入导图
证据核验（1）	伪造摘录标记为未匹配；证据须归属当前块
合并安全（2）	树完整保留；语义相反的结论不合并
异常处理（1）	加密/扫描 PDF 给出可操作错误
协议健壮（2）	非法 JSON 修复；密钥脱敏；401 不泄露正文
导图安全（1）	标签注入字符被清除
上传流程（1）	浏览器级：上传 → 轮询 → 看板打开
离线交互（2）	断网渲染、节点点击、四种导出、移动端
界面回归（2）	长文件名、可恢复错误、键盘筛选、触达区域
访问控制（1）	跨站请求 403；结果文件白名单

表 3: 自动化测试覆盖（16 项全部通过，括号内为用例数）。

次数（每轮不超过 $\lceil n/24 \rceil$，轮数由分支因子 8 决定），$F \in \{0,1\}$ 为末轮小批量归纳；另有至多 $2C$ 次结构修复重试。输入开销与全文长度线性相关（每块约 CHUNK_CHARS 字符），输出以 LLM_MAX_TOKENS 为上界。教学样例实测：4 页、46 个来源块、3 个分析块、11 个节点，共 5 次调用（3 次分析 + 2 次归纳），无修复重试，与该模型一致。



图 7: 移动端（390 pt 视口）：三栏折叠为单列纵向排布，索引、导图与详情仍可独立操作，无横向溢出。

4.5 端到端界面测试

我们在浏览器中对 12 项关键功能逐一操作并截图（图 2–7）：配置检测、文件选择、进度反馈、完成跳转、导图渲染、节点选择、证据定位、原文高亮、关键词搜索、局限性筛选、结构图切换、深色主题、主题折叠与移动端布局，全部符合预期。测试经本地模拟模型接口驱动真实上传流程完成，看板由该次运行实际生成而非预置文件。界面近期按“克制的科学编辑风格”完成改版——单一蓝色主色、衬线标题、编号栏目（研究索引 / 阅读笔记）——本报告全部截图均为改版后实测。

5 与比赛要求的对照

表 4 对照大赛评审维度给出状态。基础部分（提取、分析、导图、看板、一键化）全部达成；提高部分中页码溯源、搜索、导图切换、导出、主题切换、语法自动修复与读者友好解释均已实现，未声称完成的包括图像公式理解、自动 OCR 与独立语义事实核验。

评审维度	分值	状态与依据
一键跑通	30	已达成：命令行与上传界面均一次触发全流程
解析准确	25	机制就绪并经真实双栏 PDF 抽取核查；语义质量待真实模型验收
看板可用	20	已达成：离线 0 外部请求，交互齐全
内容深度	20	已实现：页码/章节/摘录溯源、批判性标注、通俗解释
稳定鲁棒	15	已实现：JSON 修复、网络重试、导图规则修复、完整性断言
工程规范	10	已达成：文档完备、密钥不落盘、依赖可复现

表 4: 与大赛评审维度的对照（合计 120 分）。

6 局限与展望

系统目前存在四点局限。（1）**模型质量未经验收**：全部定量结果基于确定性模拟响应或抽取层核查，接入主办方 DeepSeek V4 Pro 后的科学分析准确率仍需人工核验；（2）**文本型 PDF 边界**：扫描件与图片型公式超出基础承诺，系统以显式警告而非静默降级处理；（3）**摘录匹配非蕴含判定**：证据核验只能确认引文存在，结论正确性仍需读者结合上下文判断，接入独立的蕴含核验通道是下一步方向；（4）**跨平台验证范围**：macOS 环境为本轮补充实测，正式提交材料仍以已声明的 Windows/Python 3.12 组合为准。此外，模拟接口仅覆盖教学样例关键词，对真实模型行为的回归价值有限，未来可扩充为基于录制响应的更广覆盖。

7 结论

研脉系统以来源块与证据核验为中心组织整条流水线，将“模型会出错”作为设计前提而非异常路径，实现了从论文 PDF 到证据可溯、可离线使用的思维导图看板的一键转换。16 项自动化测试与 12 项界面功能测试全部通过，陌生论文抽取与离线场景核查未发现阻断性缺陷。系统已具备比赛基础部分的完整能力，剩余工作集中于真实模型接入后的质量验收。

References

DeepSeek-AI. 2024. DeepSeek-V3 technical report. *arXiv preprint arXiv:2412.19437*.

Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. 2020. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*.

Microsoft. 2025. Playwright. https://playwright.dev.

PyMuPDF Team. 2025. PyMuPDF4LLM: LLM-friendly PDF text extraction. https://github.com/pymupdf/pymupdf4llm. AGPL-3.0，版本 1.28.2.

Sebastián Ramírez et al. 2025. FastAPI. https://fastapi.tiangolo.com.

Hannah Rashkin, Vitaly Nikolaev, Matthew Lamm, Lora Aroyo, Michael Collins, Dipanjan Das, Slav Petrov, Gaurav Singh Tomar, Iulia Turc, and David Reitter. 2023. Measuring attribution in natural language generation models. *Computational Linguistics*, 49(4):777–840.

ScholarFlow Team. 2026. ScholarFlow. https://github.com/bcefghj/scholarflow. Commit cc66f78，MIT.

Jeffery D. Stone. 2025. mindmap-generator. https://github.com/Dicklesworthstone/mindmap-generator. Commit 4b835da.

Knut Sveidqvist et al. 2025. Mermaid: Diagramming and charting tool. https://mermaid.js.org. 版本 11.12.0.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems*.